

Modelo Predictivo para la Mortalidad en Urgencias por Trauma: Integración de Variables Clínicas y Socioespaciales en Cali 2012-2013

Nicolas Orozco Echeverri, Andrea Valencia Orozco

Tutores:

Alberto Federico García MD, MSc.
Santiago Ortíz, PhD(c)

June 23, 2024



Agenda

Contexto

Justificación

Objetivos

Estado del Arte

Metodología

Resultados

Conclusiones

Bibliografía

Contexto

Impacto global del trauma

- Principal causa de mortalidad en adultos jóvenes (<45 años)
- 1.9 millones de muertes anuales

Contexto

Impacto global del trauma

- Principal causa de mortalidad en adultos jóvenes (<45 años)
- 1.9 millones de muertes anuales

Contexto en Colombia

- Alta mortalidad por trauma, especialmente en Cali
- Desigualdad en salud influye en la mortalidad por trauma

PRIMERAS 10 CAUSAS DE MUERTE EN HOMBRES Y MUJERES SEGÚN GRUPOS DE CAUSAS

Total nacional

Grupo de causas	Año corrido 2023					
	Total	Porcentaje	Hombres	Porcentaje	Mujeres	Porcentaje
Total nacional	156.351	100%	85.642	100%	70.695	100%
Enfermedades isquémicas del corazón	26.519	17%	14.250	16,6%	12.269	17,4%
Enfermedades cerebrovasculares	10.072	6,4%	4.696	5,5%	5.376	7,6%
Enfermedades crónicas de las vías respiratorias inferiores	9.288	5,9%	4.761	5,6%	4.527	6,4%
Agresiones (homicidios)	7.962	5,1%	7.401	8,6%	559	0,8%
Enfermedades hipertensivas	5.751	3,7%	2.769	3,2%	2.982	4,2%
Infecciones respiratorias agudas	5.719	3,7%	3.000	3,5%	2.719	3,8%

Contexto

Atención prehospitalaria

- Tiempo de atención crítico: 8-10% aumento en riesgo de mortalidad por cada 10 minutos de retraso
- Hora dorada: período crítico de intervención

Contexto

Atención prehospitalaria

- Tiempo de atención crítico: 8-10% aumento en riesgo de mortalidad por cada 10 minutos de retraso
- Hora dorada: período crítico de intervención

Determinantes sociales y geoespaciales

- Violencia urbana, pobreza, desigualdad en acceso a salud

Contexto

Atención prehospitalaria

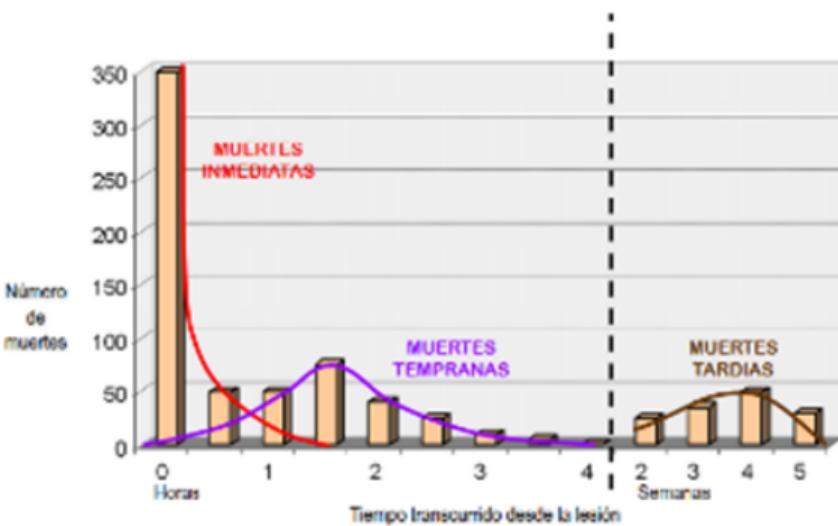
- Tiempo de atención crítico: 8-10% aumento en riesgo de mortalidad por cada 10 minutos de retraso
- Hora dorada: período crítico de intervención

Determinantes sociales y geoespaciales

- Violencia urbana, pobreza, desigualdad en acceso a salud

Avances en análisis de datos

- Uso de aprendizaje automático para predecir resultados y mejorar decisiones de tratamiento



Justificación

Importancia del Proyecto

- Mejorar la respuesta médica y los resultados a largo plazo.
- Formular políticas públicas efectivas basadas en datos.
- Implementar soluciones holísticas y sostenibles.

Justificación

Importancia del Proyecto

- Mejorar la respuesta médica y los resultados a largo plazo.
- Formular políticas públicas efectivas basadas en datos.
- Implementar soluciones holísticas y sostenibles.

Implicaciones

- Reducir mortalidad y discapacidad entre jóvenes.
- Disminuir carga financiera sobre el sistema de salud y familias.
- Promover un entorno seguro y una sociedad resiliente.

Justificación

Importancia del Proyecto

- Mejorar la respuesta médica y los resultados a largo plazo.
- Formular políticas públicas efectivas basadas en datos.
- Implementar soluciones holísticas y sostenibles.

Implicaciones

- Reducir mortalidad y discapacidad entre jóvenes.
- Disminuir carga financiera sobre el sistema de salud y familias.
- Promover un entorno seguro y una sociedad resiliente.

Modelos Supervisados

- Integración de datos clínicos, sociales y geoespaciales.
- Uso de algoritmos para identificar patrones y relaciones.
- Mejorar predicción y comprensión de resultados en trauma.
- Aprendizaje por refuerzo para aumentar adaptabilidad y precisión.

Objetivos

Objetivo General

Analizar el impacto en la sobrevida de los pacientes con trauma basado en las características clínicas, sociales y geoespaciales del sitio del evento, con el uso de modelos de aprendizaje supervisado, para optimizar la atención del trauma y las redes de direccionamiento desde el punto de vista de salud pública.

Objetivos

Objetivo General

Analizar el impacto en la sobrevida de los pacientes con trauma basado en las características clínicas, sociales y geoespaciales del sitio del evento, con el uso de modelos de aprendizaje supervisado, para optimizar la atención del trauma y las redes de direccionamiento desde el punto de vista de salud pública.

- Analizar las características sociodemográficas, geoespaciales y clínicas del ingreso de los pacientes con trauma atendidos en tres centros médicos de la ciudad.

Objetivos

Objetivo General

Analizar el impacto en la sobrevida de los pacientes con trauma basado en las características clínicas, sociales y geoespaciales del sitio del evento, con el uso de modelos de aprendizaje supervisado, para optimizar la atención del trauma y las redes de direccionamiento desde el punto de vista de salud pública.

- Analizar las características sociodemográficas, geoespaciales y clínicas del ingreso de los pacientes con trauma atendidos en tres centros médicos de la ciudad.
- Determinar el impacto de las características sociales del sitio del trauma y la distancia al centro de atención en la sobrevida de los pacientes.

Objetivos

Objetivo General

Analizar el impacto en la sobrevida de los pacientes con trauma basado en las características clínicas, sociales y geoespaciales del sitio del evento, con el uso de modelos de aprendizaje supervisado, para optimizar la atención del trauma y las redes de direccionamiento desde el punto de vista de salud pública.

- Analizar las características sociodemográficas, geoespaciales y clínicas del ingreso de los pacientes con trauma atendidos en tres centros médicos de la ciudad.
- Determinar el impacto de las características sociales del sitio del trauma y la distancia al centro de atención en la sobrevida de los pacientes.
- Predecir la mortalidad de los pacientes con trauma con el uso de modelos de aprendizaje supervisado.

Estado del Arte

Referencia	Resumen
Yu et al. (2024) [1]	Estudio sobre el uso de modelos de aprendizaje automático (SVM, Random Forest, ANN, XGBoost) para predecir la complejidad y mortalidad en pacientes politraumátizados. XGBoost mostró mejor rendimiento con 90% de precisión y AUC del 82%. Identificaron predictores clínicos como el hematoma intracranegal.
Hunter et al. (2023) [2]	
Nehemiah T et al. (2017) [3]	
Vaz et al. (2021) [4]	
Ghandour et al. (2020) [5]	
Tsiklidis et al. (2020) [6]	

Table: Resumen de estudios sobre el uso de aprendizaje automático en el ámbito del trauma (Parte 1).

Estado del Arte

Referencia	Resumen
Yu et al. (2024) [1]	Estudio sobre el uso de modelos de aprendizaje automático (SVM, Random Forest, ANN, XGBoost) para predecir la complejidad y mortalidad en pacientes politraumatizados. XGBoost mostró mejor rendimiento con 90% de precisión y AUC del 82%. Identificaron predictores clínicos como el hematoma intracranegal.
Hunter et al. (2023) [2]	Revisión del uso de IA en la atención del trauma, destacando su integración en la predicción de lesiones y gestión de emergencias. A pesar de su potencial, la aplicación clínica de IA en cirugía de trauma aún está en desarrollo y requiere más investigación.
Nehemiah T et al. (2017) [3]	
Vaz et al. (2021) [4]	
Ghandour et al. (2020) [5]	
Tsiklidis et al. (2020) [6]	

Table: Resumen de estudios sobre el uso de aprendizaje automático en el ámbito del trauma (Parte 1).

Estado del Arte

Referencia	Resumen
Yu et al. (2024) [1]	Estudio sobre el uso de modelos de aprendizaje automático (SVM, Random Forest, ANN, XGBoost) para predecir la complejidad y mortalidad en pacientes politraumatizados. XGBoost mostró mejor rendimiento con 90% de precisión y AUC del 82%. Identificaron predictores clínicos como el hematoma intracranegal.
Hunter et al. (2023) [2]	Revisión del uso de IA en la atención del trauma, destacando su integración en la predicción de lesiones y gestión de emergencias. A pesar de su potencial, la aplicación clínica de IA en cirugía de trauma aún está en desarrollo y requiere más investigación.
Nehemiah T et al. (2017) [3]	
Vaz et al. (2021) [4]	Uso de datos abiertos y aprendizaje automático para analizar lesiones en áreas urbanas de Toronto. Identificaron patrones geográficos y temporales en la ocurrencia de lesiones, sugiriendo políticas de prevención basadas en datos.
Ghandour et al. (2020) [5]	
Tsiklidis et al. (2020) [6]	

Table: Resumen de estudios sobre el uso de aprendizaje automático en el ámbito del trauma (Parte 1).

Estado del Arte

Referencia	Resumen
Yu et al. (2024) [1]	Estudio sobre el uso de modelos de aprendizaje automático (SVM, Random Forest, ANN, XGBoost) para predecir la complejidad y mortalidad en pacientes politraumatizados. XGBoost mostró mejor rendimiento con 90% de precisión y AUC del 82%. Identificaron predictores clínicos como el hematoma intracranegal.
Hunter et al. (2023) [2]	Revisión del uso de IA en la atención del trauma, destacando su integración en la predicción de lesiones y gestión de emergencias. A pesar de su potencial, la aplicación clínica de IA en cirugía de trauma aún está en desarrollo y requiere más investigación.
Nehemiah T et al. (2017) [3]	Revisión sistemática de modelos de ML para predecir resultados en pacientes con trauma. Redes neuronales mostraron alta capacidad de predicción. Se enfatiza la necesidad de ensayos clínicos prospectivos para confirmar la validez de los modelos.
Vaz et al. (2021) [4]	Uso de datos abiertos y aprendizaje automático para analizar lesiones en áreas urbanas de Toronto. Identificaron patrones geográficos y temporales en la ocurrencia de lesiones, sugiriendo políticas de prevención basadas en datos.
Ghandour et al. (2020) [5]	
Tsiklidis et al. (2020) [6]	

Table: Resumen de estudios sobre el uso de aprendizaje automático en el ámbito del trauma (Parte 1).

Estado del Arte

Referencia	Resumen
Yu et al. (2024) [1]	Estudio sobre el uso de modelos de aprendizaje automático (SVM, Random Forest, ANN, XGBoost) para predecir la complejidad y mortalidad en pacientes politraumatizados. XGBoost mostró mejor rendimiento con 90% de precisión y AUC del 82%. Identificaron predictores clínicos como el hematoma intracranegal.
Hunter et al. (2023) [2]	Revisión del uso de IA en la atención del trauma, destacando su integración en la predicción de lesiones y gestión de emergencias. A pesar de su potencial, la aplicación clínica de IA en cirugía de trauma aún está en desarrollo y requiere más investigación.
Nehemiah T et al. (2017) [3]	Revisión sistemática de modelos de ML para predecir resultados en pacientes con trauma. Redes neuronales mostraron alta capacidad de predicción. Se enfatiza la necesidad de ensayos clínicos prospectivos para confirmar la validez de los modelos.
Vaz et al. (2021) [4]	Uso de datos abiertos y aprendizaje automático para analizar lesiones en áreas urbanas de Toronto. Identificaron patrones geográficos y temporales en la ocurrencia de lesiones, sugiriendo políticas de prevención basadas en datos.
Ghandour et al. (2020) [5]	Análisis de factores de riesgo en accidentes de tráfico usando ML. Identificaron 7 variables significativamente asociadas con fatalidades en accidentes. Los hallazgos buscan informar políticas de seguridad vial.
Tsiklidis et al. (2020) [6]	

Table: Resumen de estudios sobre el uso de aprendizaje automático en el ámbito del trauma (Parte 1).

Estado del Arte

Referencia	Resumen
Yu et al. (2024) [1]	Estudio sobre el uso de modelos de aprendizaje automático (SVM, Random Forest, ANN, XGBoost) para predecir la complejidad y mortalidad en pacientes politraumatizados. XGBoost mostró mejor rendimiento con 90% de precisión y AUC del 82%. Identificaron predictores clínicos como el hematoma intracranegal.
Hunter et al. (2023) [2]	Revisión del uso de IA en la atención del trauma, destacando su integración en la predicción de lesiones y gestión de emergencias. A pesar de su potencial, la aplicación clínica de IA en cirugía de trauma aún está en desarrollo y requiere más investigación.
Nehemiah T et al. (2017) [3]	Revisión sistemática de modelos de ML para predecir resultados en pacientes con trauma. Redes neuronales mostraron alta capacidad de predicción. Se enfatiza la necesidad de ensayos clínicos prospectivos para confirmar la validez de los modelos.
Vaz et al. (2021) [4]	Uso de datos abiertos y aprendizaje automático para analizar lesiones en áreas urbanas de Toronto. Identificaron patrones geográficos y temporales en la ocurrencia de lesiones, sugiriendo políticas de prevención basadas en datos.
Ghandour et al. (2020) [5]	Ánalisis de factores de riesgo en accidentes de tráfico usando ML. Identificaron 7 variables significativamente asociadas con fatalidades en accidentes. Los hallazgos buscan informar políticas de seguridad vial.
Tsiklidis et al. (2020) [6]	Predicción de mortalidad en pacientes de trauma usando un clasificador de boosting de 400 estimadores. Identificaron que la escala de coma de Glasgow y la presión arterial sistólica son predictores significativos.

Table: Resumen de estudios sobre el uso de aprendizaje automático en el ámbito del trauma (Parte 1).

Estado del Arte

Referencia	Resumen
Yu et al. (2024) [1]	Estudio sobre el uso de modelos de aprendizaje automático (SVM, Random Forest, ANN, XGBoost) para predecir la complejidad y mortalidad en pacientes politraumatizados. XGBoost mostró mejor rendimiento con 90% de precisión y AUC del 82%. Identificaron predictores clínicos como el hematoma intracranegal.
Hunter et al. (2023) [2]	Revisión del uso de IA en la atención del trauma, destacando su integración en la predicción de lesiones y gestión de emergencias. A pesar de su potencial, la aplicación clínica de IA en cirugía de trauma aún está en desarrollo y requiere más investigación.
Nehemiah T et al. (2017) [3]	Revisión sistemática de modelos de ML para predecir resultados en pacientes con trauma. Redes neuronales mostraron alta capacidad de predicción. Se enfatiza la necesidad de ensayos clínicos prospectivos para confirmar la validez de los modelos.
Vaz et al. (2021) [4]	Uso de datos abiertos y aprendizaje automático para analizar lesiones en áreas urbanas de Toronto. Identificaron patrones geográficos y temporales en la ocurrencia de lesiones, sugiriendo políticas de prevención basadas en datos.
Ghandour et al. (2020) [5]	Ánalisis de factores de riesgo en accidentes de tráfico usando ML. Identificaron 7 variables significativamente asociadas con fatalidades en accidentes. Los hallazgos buscan informar políticas de seguridad vial.
Tsiklidis et al. (2020) [6]	Predicción de mortalidad en pacientes de trauma usando un clasificador de boosting de 400 estimadores. Identificaron que la escala de coma de Glasgow y la presión arterial sistólica son predictores significativos.

Table: Resumen de estudios sobre el uso de aprendizaje automático en el ámbito del trauma (Parte 1).

Estado del Arte

Referencia	Resumen
Hassanzadeh et al. (2023) [7]	Predicción de mortalidad hospitalaria en pacientes con lesiones traumáticas usando técnicas de SMOTE y varios algoritmos de ML. Random Forest y Redes Neuronales mostraron alto rendimiento.
Dirago et al. (2024) [8]	Análisis geoespacial de la vulnerabilidad social y violencia por armas de fuego en Chicago. Identificaron una correlación significativa entre vulnerabilidad social y la incidencia de violencia armada.
Jay (2020) [9]	Estudio de la relación entre puntos de venta de alcohol y violencia por armas de fuego en Filadelfia usando imágenes satelitales y ML. Se encontró mayor probabilidad de tiroteos cerca de tiendas de alcohol.
Bedard et al. (2020) [10]	Revisión de cómo el tiempo de atención prehospitalaria afecta los resultados de trauma. Destacaron la necesidad de más estudios en países de ingresos bajos y medios.
Rojas et al. (2017) [11]	Modelo de localización de ambulancias en Cali, Colombia, para mejorar la eficiencia del servicio. Utilizaron el problema de Máximo Cubrimiento Esperado (MEXCLP) y datos históricos para optimizar la cobertura.

Table: Resumen de estudios sobre el uso de aprendizaje automático en el ámbito del trauma (Parte 2).

Metodología

Datos de estudio

Estudio de cohorte observacional para evaluar la eficacia del TRISS en la predicción de mortalidad en pacientes con traumas moderados y severos en cuatro hospitales de Cali entre diciembre de 2012 y junio de 2013.

Metodología

Datos de estudio

Estudio de cohorte observacional para evaluar la eficacia del TRISS en la predicción de mortalidad en pacientes con traumas moderados y severos en cuatro hospitales de Cali entre diciembre de 2012 y junio de 2013.

Criterios de inclusión:

- Ingreso al hospital para lesiones traumáticas.
- ≥ 18 años.
- Transferencia directa del sitio de trauma o sin intervenciones previas.

Metodología

Datos de estudio

Estudio de cohorte observacional para evaluar la eficacia del TRISS en la predicción de mortalidad en pacientes con traumas moderados y severos en cuatro hospitales de Cali entre diciembre de 2012 y junio de 2013.

Criterios de inclusión:

- Ingreso al hospital para lesiones traumáticas.
- ≥ 18 años.
- Transferencia directa del sitio de trauma o sin intervenciones previas.

Criterios de exclusión:

- Intervalo trauma-ingreso > 6 horas.
- Intervención quirúrgica o transfusión previa.
- Trauma menor (ISS < 8).
- Quemaduras.
- Lesiones no traumáticas (e.g., caída por accidente cerebrovascular).
- Embarazo detectado clínicamente.
- Muertos a la admisión.

Metodología

Datos de estudio

Estudio de cohorte observacional para evaluar la eficacia del TRISS en la predicción de mortalidad en pacientes con traumas moderados y severos en cuatro hospitales de Cali entre diciembre de 2012 y junio de 2013.

Criterios de inclusión:

- Ingreso al hospital para lesiones traumáticas.
- ≥ 18 años.
- Transferencia directa del sitio de trauma o sin intervenciones previas.

Criterios de exclusión:

- Intervalo trauma-ingreso > 6 horas.
- Intervención quirúrgica o transfusión previa.
- Trauma menor (ISS < 8).
- Quemaduras.
- Lesiones no traumáticas (e.g., caída por accidente cerebrovascular).
- Embarazo detectado clínicamente.
- Muertos a la admisión.

Variables disponibles:

- Sociodemográficas
- Clínicas
- Georreferenciación

Metodología

Limpieza y Preparación de Datos:

- Eliminación de duplicados y gestión de datos incompletos.
- Corrección de errores, valores atípicos e inconsistencias.
- Estandarización de formatos y resolución de discrepancias.
- Transformación y reorganización de datos en bruto.
- Integración de múltiples fuentes, conversión de tipos de datos, selección de variables relevantes e ingeniería de características.

Metodología

Limpieza y Preparación de Datos:

- Eliminación de duplicados y gestión de datos incompletos.
- Corrección de errores, valores atípicos e inconsistencias.
- Estandarización de formatos y resolución de discrepancias.
- Transformación y reorganización de datos en bruto.
- Integración de múltiples fuentes, conversión de tipos de datos, selección de variables relevantes e ingeniería de características.

Análisis Exploratorio de Datos (EDA):

- Comprensión profunda mediante visualización y estadísticas descriptivas.
- Identificación de patrones, anomalías e hipótesis.
- Orientación para la selección de técnicas estadísticas y de modelado.

Metodología

Limpieza y Preparación de Datos:

- Eliminación de duplicados y gestión de datos incompletos.
- Corrección de errores, valores atípicos e inconsistencias.
- Estandarización de formatos y resolución de discrepancias.
- Transformación y reorganización de datos en bruto.
- Integración de múltiples fuentes, conversión de tipos de datos, selección de variables relevantes e ingeniería de características.

Análisis Exploratorio de Datos (EDA):

- Comprensión profunda mediante visualización y estadísticas descriptivas.
- Identificación de patrones, anomalías e hipótesis.
- Orientación para la selección de técnicas estadísticas y de modelado.

División del Conjunto de Datos:

- Conjunto de entrenamiento: 70% del total, 387 instancias.
- Conjunto de validación: 30% del total, 166 instancias.

Metodología

Protocolo de entrenamiento y evaluación de modelos

- Se optimizaron los hiperparámetros utilizando el conjunto de entrenamiento (387 instancias), aplicando *Stratified K-Fold* para mantener la proporción de clases.

Metodología

Protocolo de entrenamiento y evaluación de modelos

- Se optimizaron los hiperparámetros utilizando el conjunto de entrenamiento (387 instancias), aplicando *Stratified K-Fold* para mantener la proporción de clases.
- Mediante el método de optimización bayesiana, se aplicó sistemáticamente este procedimiento a cada uno de los modelos entrenados en los *K-Folds* generados por la técnica de validación cruzada, con $K = 2$.

Metodología

Protocolo de entrenamiento y evaluación de modelos

- Se optimizaron los hiperparámetros utilizando el conjunto de entrenamiento (387 instancias), aplicando *Stratified K-Fold* para mantener la proporción de clases.
- Mediante el método de optimización bayesiana, se aplicó sistemáticamente este procedimiento a cada uno de los modelos entrenados en los *K-Folds* generados por la técnica de validación cruzada, con $K = 2$.
- La validación final del modelo se realizó con el conjunto de prueba compuesto por 166 instancias, evaluando su capacidad de generalización y robustez en condiciones reales.

Metodología

Selección de variables para el modelado

- Resultados del EDA

Metodología

Selección de variables para el modelado

- Resultados del EDA
- Evaluación basada en el criterio de expertos

Metodología

Selección de variables para el modelado

- Resultados del EDA
- Evaluación basada en el criterio de expertos
- Significancia estadística: Test Chi-cuadrado y/o prueba U de Mann-Whitney

Metodología

Selección de variables para el modelado

- Resultados del EDA
- Evaluación basada en el criterio de expertos
- Significancia estadística: Test Chi-cuadrado y/o prueba U de Mann-Whitney
- Criterio de expertos basado en los Riesgos Relativos (RR) obtenidos de la regresión de Poisson con errores estándar robustos

Metodología

Table: Lista de variables seleccionadas

Por grupo de variables

Variables Clínicas

lesion_extremidades	presion_arterial_sistolica_ing
escala_glasgow_ing	score_severidad_lesiones
score_severidad_urgencias_anatomico	lesion_cabeza
lesion_torax	lesion_abdomen_pelvis
lesion_externo	muerte

frecuencia_respiratoria_ing
score_severidad_urgencias
lesion_cara

Variables DANE

indice_pobreza_multidimensional_DANE	viviendas_totales_manzana_DANE	hogares_totales_manzana_DANE
habitaciones_habitantes_DANE	deficit_habitacional_cuantitativo_DANE	deficit_habitacional_cualitativo_DANE
porcentaje_deficit_vivienda_DANE	porcentaje_deficit_vivienda_cuantitativo_DANE	porcentaje_deficit_vivienda_cualitativo_DANE
nivel_vulnerabilidad_DANE	riesgo_embarazo_adolescente_DANE	elegibilidad_jovenes_empleo_DANE

Variables Sociodemográficas y Distancias

estrato_evento_trauma	atencion_centro_mas_lejano	distance_openrout_tx_center(m)
distancia_retardo_min	sexo	mecanismo_lesion_new
trauma_penetrante_new	transporte_llevado	seg_social_new
edad		

Metodología

Optimización Bayesiana de Hiperparámetros

Hiperparámetro	Rango	Descripción
Tipo de imputación (<i>type_imputer</i>)	(0, 1)	Los valores entre 0 y 0.5 indican el uso de KNN, mientras que los valores mayores a 0.5 indican el uso de imputación simple usando una medida de resumen.
Estrategia de imputación (<i>strategy</i>)	(0, 1)	Los valores entre 0 y 0.5 corresponden a la estrategia de imputación por media, y los valores mayores a 0.5 corresponden a la imputación por mediana.
Número de vecinos (<i>knn_k</i>)	(3, 10)	Vecinos en KNN
Componentes principales (<i>num_comp</i>)	(2, 30)	Componentes en ACP
Alpha para LASSO (<i>alpha</i>)	(0.01, 0.7)	Penalización en LASSO

Metodología

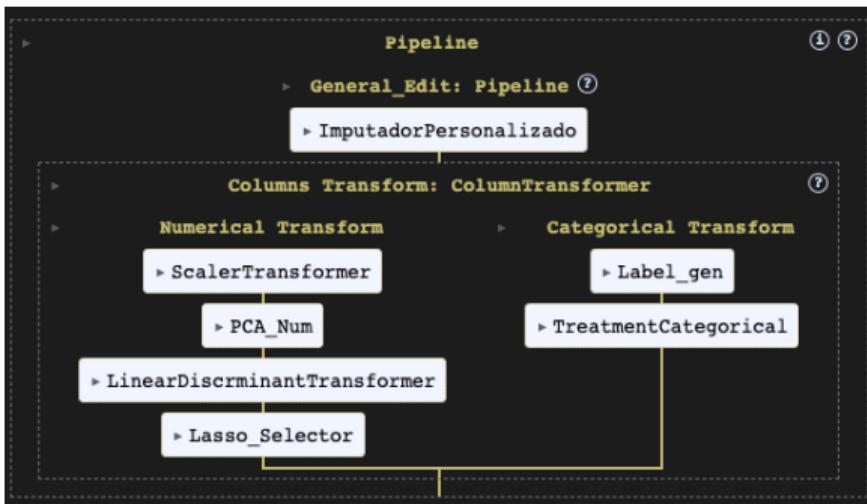


Figure: Pipeline de Procesamiento

- **Regresión logística**

- Regresión logística
- Con regularización LASSO
- Con regularización Ridge
- Con regularización Elastic-net

- **Máquina de vectores de soporte**

- Kernel sigmoide
- Kernel lineal
- Kernel RBF (Radial Basis Function)
- Kernel polinomial

- **Métodos de ensamblaje**

- Random Forest
- XGBoost

- **Redes neuronales**

- Red neuronal artificial feedforward

Metodología

La evaluación de los modelos se realizó utilizando las siguientes métricas:

- **F1-score:** Medida que combina precisión y recall.

Metodología

La evaluación de los modelos se realizó utilizando las siguientes métricas:

- **F1-score:** Medida que combina precisión y recall.
- **Sensibilidad:** También conocida como recall, mide la proporción de verdaderos positivos correctamente identificados.

Metodología

La evaluación de los modelos se realizó utilizando las siguientes métricas:

- **F1-score:** Medida que combina precisión y recall.
- **Sensibilidad:** También conocida como recall, mide la proporción de verdaderos positivos correctamente identificados.
- **Especificidad:** Mide la proporción de verdaderos negativos correctamente identificados.

Metodología

La evaluación de los modelos se realizó utilizando las siguientes métricas:

- **F1-score:** Medida que combina precisión y recall.
- **Sensibilidad:** También conocida como recall, mide la proporción de verdaderos positivos correctamente identificados.
- **Especificidad:** Mide la proporción de verdaderos negativos correctamente identificados.
- **Curva ROC** Gráfica que muestra el rendimiento del modelo en función de la tasa de verdaderos positivos y la tasa de falsos positivos.

Metodología

La evaluación de los modelos se realizó utilizando las siguientes métricas:

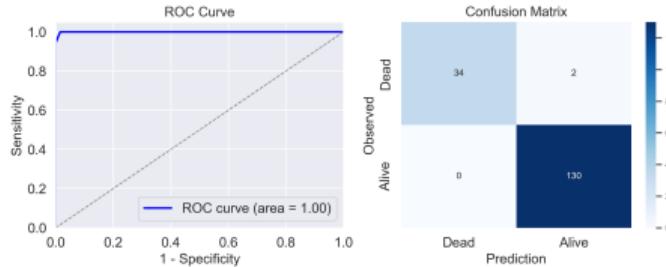
- **F1-score:** Medida que combina precisión y recall.
- **Sensibilidad:** También conocida como recall, mide la proporción de verdaderos positivos correctamente identificados.
- **Especificidad:** Mide la proporción de verdaderos negativos correctamente identificados.
- **Curva ROC** Gráfica que muestra el rendimiento del modelo en función de la tasa de verdaderos positivos y la tasa de falsos positivos.
- **AUC:** Área bajo la curva ROC, mide la capacidad del modelo para distinguir entre clases.

Resultados

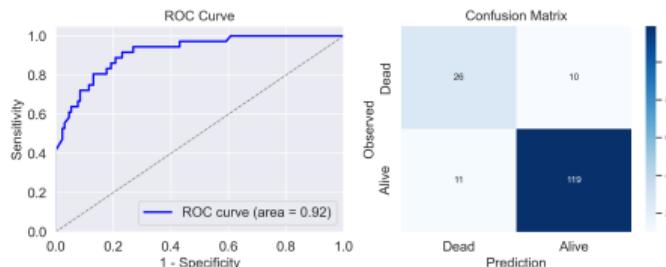
Table: Comparación del rendimiento de modelos de clasificación en los conjuntos de entrenamiento y prueba

Modelos	F1		Sensitivity		Specificity		AUC	
	Train	Test	Train	Test	Train	Test	Train	Test
Logistic regression	0.62	0.66	0.66	0.81	0.92	0.82	0.90	0.88
LASSO-Logistic regression	0.61	0.67	0.82	0.83	0.78	0.82	0.88	0.87
Ridge-Logistic regression	0.61	0.66	0.60	0.81	0.95	0.82	0.90	0.88
Elastic-net Logistic regression	0.61	0.65	0.67	0.78	0.93	0.83	0.91	0.87
SVM-Sigmoid kernel	0.58	0.61	0.60	0.47	0.88	0.98	0.76	0.73
SVM-RBF kernel	0.35	0.97	1.00	0.94	1.00	1.00	1.00	1.00
SVM-Linear kernel	0.64	0.70	0.64	0.75	0.96	0.89	0.90	0.89
SVM-Polynomial kernel	0.65	0.69	0.57	0.67	0.96	0.92	0.84	0.86
Random Forest	0.68	0.70	0.59	0.72	0.98	0.91	0.89	0.90
XGBoost	0.62	0.71	0.80	0.72	0.96	0.92	0.94	0.92
Neural Network	0.66	0.73	0.66	0.83	0.95	0.88	0.89	0.90

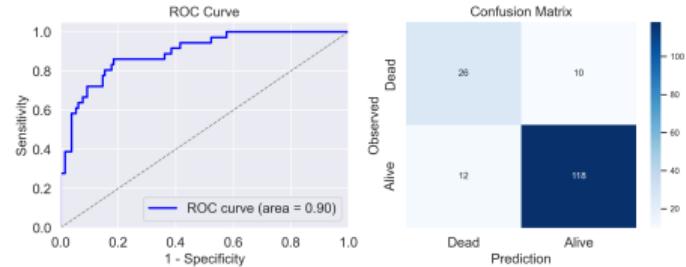
Resultados



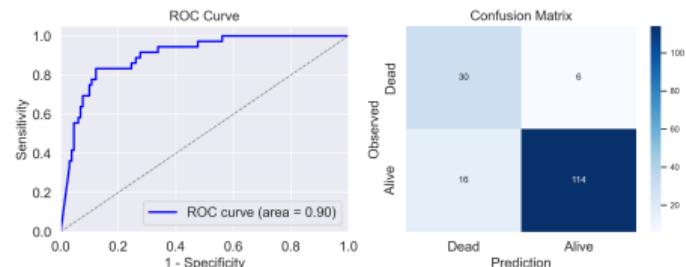
SVM-RBF Kernel



XGBoost

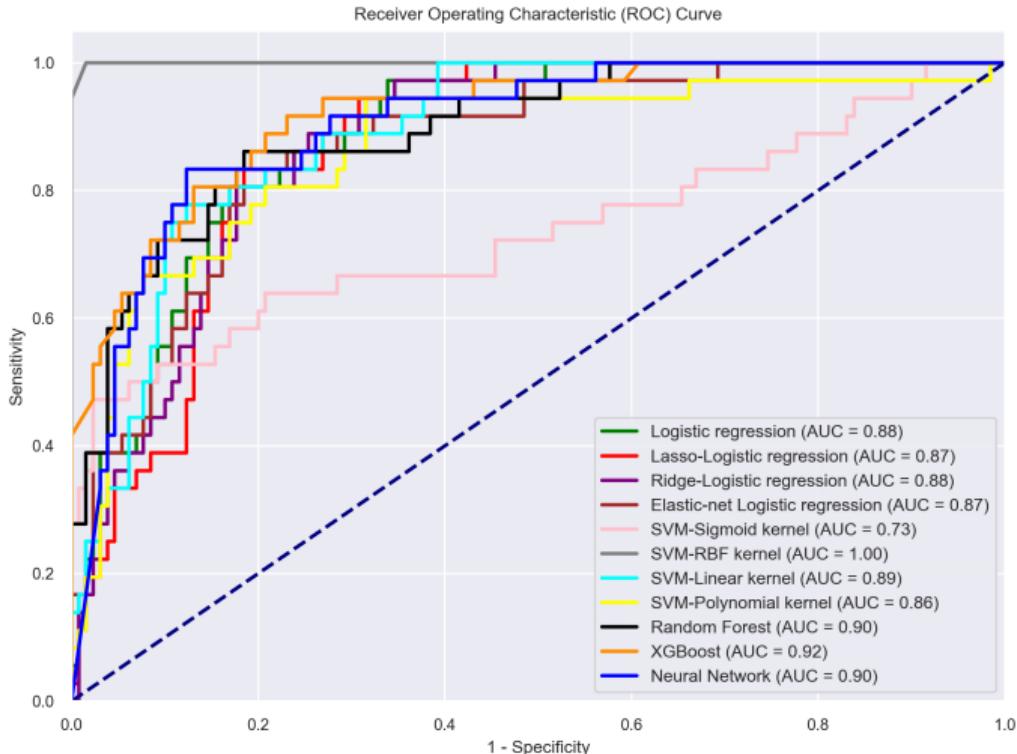


Random Forest



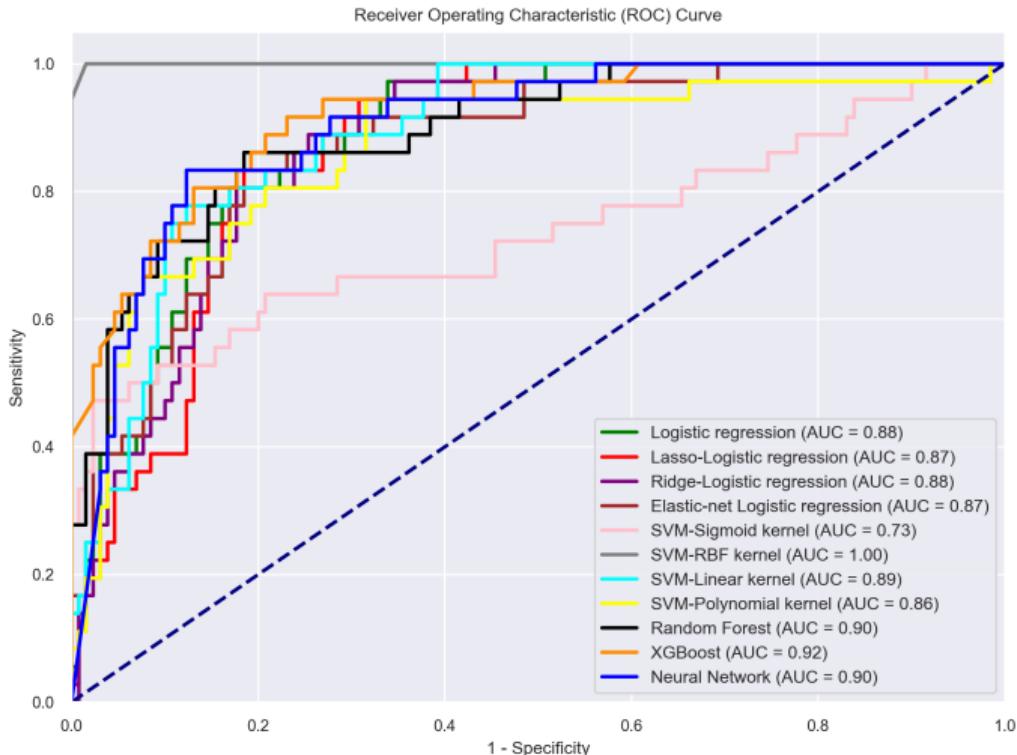
Neural Network

Resultados



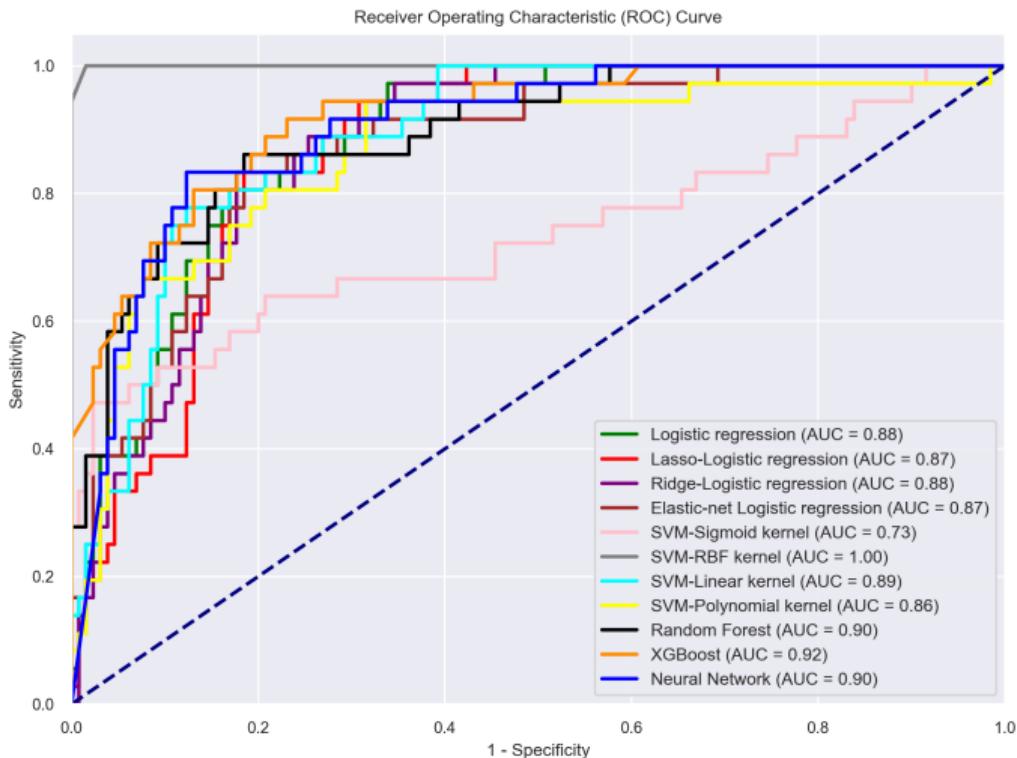
- Random Forest y XGBoost: AUCs de 0.90 y 0.92, F1-scores equilibrados.

Resultados



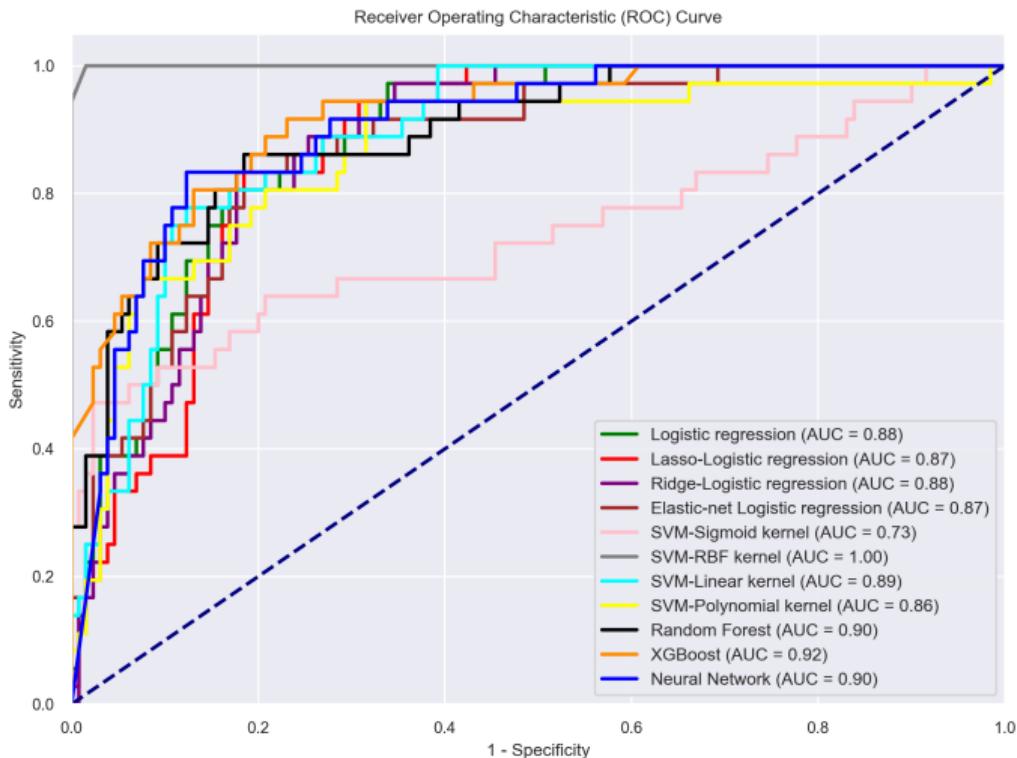
- Random Forest y XGBoost: AUCs de 0.90 y 0.92, F1-scores equilibrados.
- Red neuronal: AUC de 0.90, F1-scores aceptables, maneja datos complejos.

Resultados



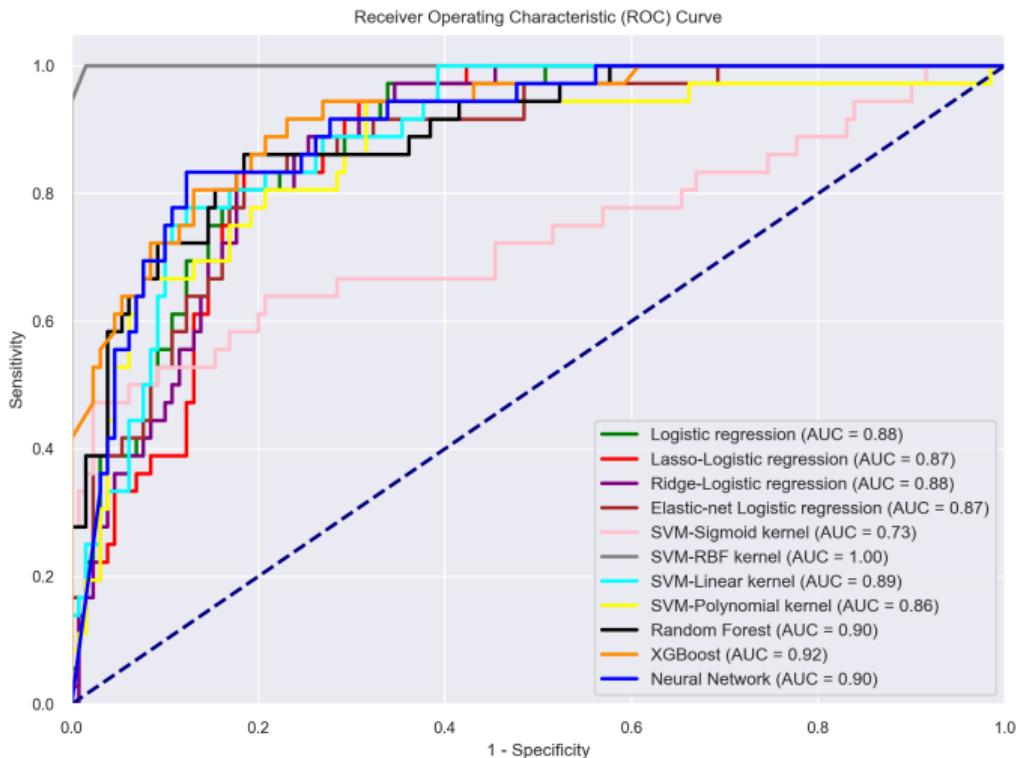
- Random Forest y XGBoost: AUCs de 0.90 y 0.92, F1-scores equilibrados.
- Red neuronal: AUC de 0.90, F1-scores aceptables, maneja datos complejos.
- SVM (kernel lineal y polinomial): AUCs de 0.89 y 0.86, buen rendimiento.

Resultados



- Random Forest y XGBoost: AUCs de 0.90 y 0.92, F1-scores equilibrados.
- Red neuronal: AUC de 0.90, F1-scores aceptables, maneja datos complejos.
- SVM (kernel lineal y polinomial): AUCs de 0.89 y 0.86, buen rendimiento.
- Random Forest y XGBoost son ideales para aplicaciones clínicas.

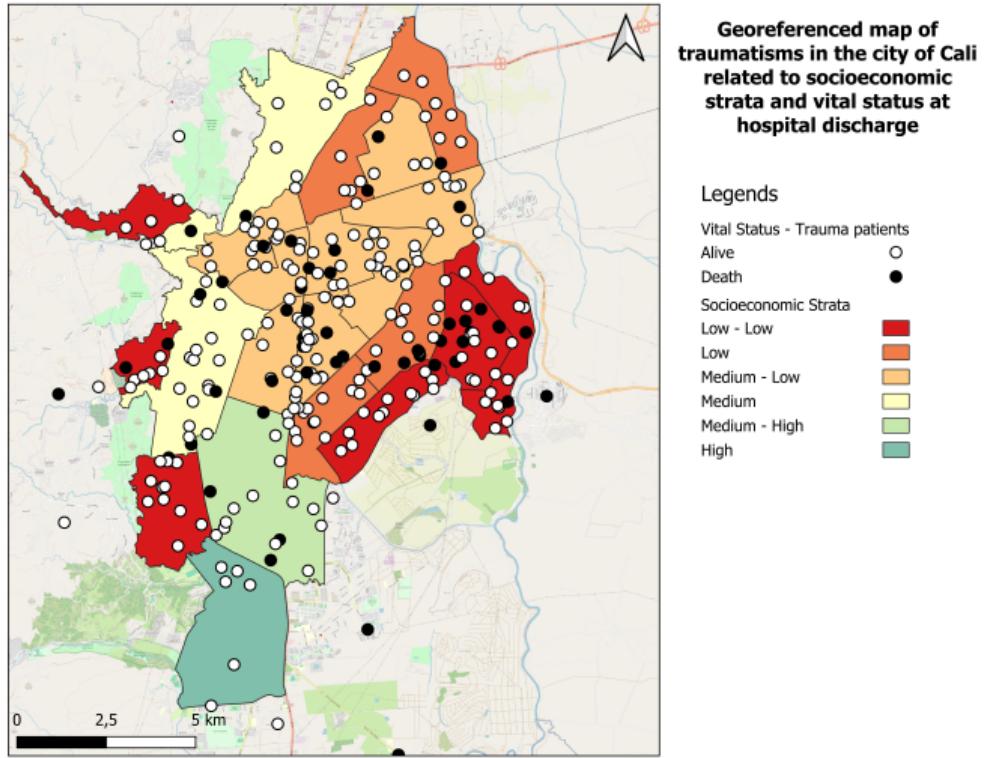
Resultados



- Random Forest y XGBoost: AUCs de 0.90 y 0.92, F1-scores equilibrados.
- Red neuronal: AUC de 0.90, F1-scores aceptables, maneja datos complejos.
- SVM (kernel lineal y polinomial): AUCs de 0.89 y 0.86, buen rendimiento.
- Random Forest y XGBoost son ideales para aplicaciones clínicas.
- Redes neuronales útiles para interacciones complejas y grandes muestras.

Visualización espacial

El mapa muestra los eventos de trauma en Cali, con puntos blancos y negros indicando pacientes fallecidos. El análisis revela que las zonas más pobres tienen más eventos y mayor mortalidad.



Conclusiones

- Los modelos pronósticos proporcionan una predicción temprana de la mortalidad en pacientes politraumatizados, mejorando así el tratamiento clínico.

Conclusiones

- Los modelos pronósticos proporcionan una predicción temprana de la mortalidad en pacientes politraumatizados, mejorando así el tratamiento clínico.
- Las variables sociodemográficas son determinantes importantes de la salud en pacientes politraumatizados, según el sitio del evento.

Conclusiones

- Los modelos pronósticos proporcionan una predicción temprana de la mortalidad en pacientes politraumatizados, mejorando así el tratamiento clínico.
- Las variables sociodemográficas son determinantes importantes de la salud en pacientes politraumatizados, según el sitio del evento.
- Los modelos de ensamble, como Random Forest y XGBoost, destacan por su capacidad para equilibrar varianza y sesgo, así como su alto desempeño en métricas clave.

Conclusiones

- Los modelos pronósticos proporcionan una predicción temprana de la mortalidad en pacientes politraumatizados, mejorando así el tratamiento clínico.
- Las variables sociodemográficas son determinantes importantes de la salud en pacientes politraumatizados, según el sitio del evento.
- Los modelos de ensamble, como Random Forest y XGBoost, destacan por su capacidad para equilibrar varianza y sesgo, así como su alto desempeño en métricas clave.
- Durante el proyecto, se enfrentaron limitaciones como la accesibilidad a datos y la calidad variable de estos, lo que debe considerarse en futuros proyectos.

Conclusiones

- Los modelos pronósticos proporcionan una predicción temprana de la mortalidad en pacientes politraumatizados, mejorando así el tratamiento clínico.
- Las variables sociodemográficas son determinantes importantes de la salud en pacientes politraumatizados, según el sitio del evento.
- Los modelos de ensamble, como Random Forest y XGBoost, destacan por su capacidad para equilibrar varianza y sesgo, así como su alto desempeño en métricas clave.
- Durante el proyecto, se enfrentaron limitaciones como la accesibilidad a datos y la calidad variable de estos, lo que debe considerarse en futuros proyectos.
- Se sugiere abordar el desbalance en la variable objetivo de mortalidad mediante métodos de balanceo como SMOTE en futuros estudios.

Conclusiones

- Los modelos pronósticos proporcionan una predicción temprana de la mortalidad en pacientes politraumatizados, mejorando así el tratamiento clínico.
- Las variables sociodemográficas son determinantes importantes de la salud en pacientes politraumatizados, según el sitio del evento.
- Los modelos de ensamble, como Random Forest y XGBoost, destacan por su capacidad para equilibrar varianza y sesgo, así como su alto desempeño en métricas clave.
- Durante el proyecto, se enfrentaron limitaciones como la accesibilidad a datos y la calidad variable de estos, lo que debe considerarse en futuros proyectos.
- Se sugiere abordar el desbalance en la variable objetivo de mortalidad mediante métodos de balanceo como SMOTE en futuros estudios.
- Reconocer las posibles limitaciones del modelo actual es crucial; para mejorar su universalidad y estabilidad, se recomienda ampliar la cohorte de pacientes y explorar otros factores relevantes.

Bibliografía I

- [1] Meiqi Yu et al. "Predicting the complexity and mortality of polytrauma patients with machine learning models". In: *Scientific reports* 14.1 (2024), p. 8302.
- [2] O. F. Hunter et al. "Science fiction or clinical reality: a review of the applications of artificial intelligence along the continuum of trauma care". In: *World J Emerg Surg* 18.1 (2023), p. 16. DOI: 10.1186/s13017-022-00469-1.
- [3] N. T. Liu and J. Salinas. "Machine Learning for Predicting Outcomes in Trauma". In: *Shock (Augusta, Ga.)* 48.5 (2017), pp. 504–510. DOI: 10.1097/SHK.0000000000000898.
- [4] Eric Vaz et al. "Open data and injuries in urban areas—A spatial analytical framework of Toronto using machine learning and spatial regressions". In: *PLoS one* 16.3 (2021), e0248285. DOI: 10.1371/journal.pone.0248285. URL: <https://doi.org/10.1371/journal.pone.0248285>.
- [5] A. J. Ghandour, H. Hammoud, and S. Al-Hajj. "Analyzing factors associated with fatal road crashes: a machine learning approach". In: *International Journal of Environmental Research and Public Health* 17.11 (2020), p. 4111.

Bibliografía II

- [6] E. J. Tsiklidis et al. "Using the National Trauma Data Bank (NTDB) and machine learning to predict trauma patient mortality at admission". In: *PLoS one* 15.11 (2020), e0242166. DOI: 10.1371/journal.pone.0242166.
- [7] R. Hassanzadeh, M. Farhadian, and H. Rafieemehr. "Hospital mortality prediction in traumatic injuries patients: comparing different SMOTE-based machine learning algorithms". In: *BMC Medical Research Methodology* 23.1 (2023), p. 101.
- [8] C. Dirago et al. "Geospatial analysis of social vulnerability, race, and firearm violence in Chicago". In: *Journal of Surgical Research* 294 (2024), pp. 66–72.
- [9] J. Jay. "Alcohol outlets and firearm violence: a place-based case-control study using satellite imagery and machine learning". In: *Injury Prevention* 26.1 (2020), pp. 61–66.
- [10] A. F. Bedard et al. "A scoping review of worldwide studies evaluating the effects of prehospital time on trauma outcomes". In: *International Journal of Emergency Medicine* 13 (2020), pp. 1–19.

Bibliografía III

- [11] C. A. Rojas-Trejos, J. González-Velasco, and M. A. López-Ramírez. "Optimization Model for the Location of Prehospital Care Ambulances in the city of Cali, Colombia". In: *International Journal of Combinatorial Optimization Problems and Informatics* 8.3 (2017), pp. 64–70.